ИТМО

Введение в GameDev: основы игрового ИИ

Лекция 4. Принятие решений и элементы машинного обучения

ГЛАВА 4 _ Agenda

1. Теория принятия решений
2. Теория полезности
3. ИИ на основе полезности
4. Машинное обучение
5. Обучение с подкреплением
6. Q-learning

ГЛАВА 4 _ Принятие решений

Теория принятия оптимальных решений* в наиболее общем смысле представляет собой совокупность математических и численных методов, ориентированных на нахождение наилучших вариантов из множества альтернатив и позволяющих избежать их полного перебора.

Теория принятия решений — обширное научное направление, которое включает в себя существенную часть методологии исследования операций и системного анализа.

*Черноиванова Е.А. Курс лекций “Исследование операций и методы оптимизации”

Об Исследовании операций от System Lab

ГЛАВА 4 _ Принятие решений

Теория принятия оптимальных решений* в наиболее общем смысле представляет собой совокупность математических и численных методов, ориентированных на нахождение наилучших вариантов из множества альтернатив и позволяющих избежать их полного перебора.

Теория принятия решений — обширное научное направление, которое включает в себя существенную часть методологии исследования операций и системного анализа.



*Черноиванова Е.А. Курс лекций “Исследование операций и методы оптимизации”

Об Исследовании операций от System Lab

ГЛАВА 4 _ Принятие решений

Теория принятия оптимальных решений* в наиболее общем смысле представляет собой совокупность математических и численных методов, ориентированных на нахождение наилучших вариантов из множества альтернатив и позволяющих избежать их полного перебора.

Теория принятия решений — обширное научное направление, которое включает в себя существенную часть методологии исследования операций и системного анализа.



Определенность ~ полная информация. Вспоминаем **лекцию 1**.

*Черноиванова Е.А. Курс лекций “Исследование операций и методы оптимизации”

Об Исследовании операций от System Lab

ГЛАВА 4 _ Принятие решений

Теория принятия оптимальных решений* в наиболее общем смысле представляет собой совокупность математических и численных методов, ориентированных на нахождение наилучших вариантов из множества альтернатив и позволяющих избежать их полного перебора.

Теория принятия решений — обширное научное направление, которое включает в себя существенную часть методологии исследования операций и системного анализа.



Определенность ~ полная информация. Вспоминаем **лекцию 1**.

Неопределенность ~ ЛПР (ИИ Агент) не знает вероятности природы (В Spore ЛПР не знало нападет ли монстр). Вспоминаем **лекцию 3**?

*Черноиванова Е.А. Курс лекций “Исследование операций и методы оптимизации”

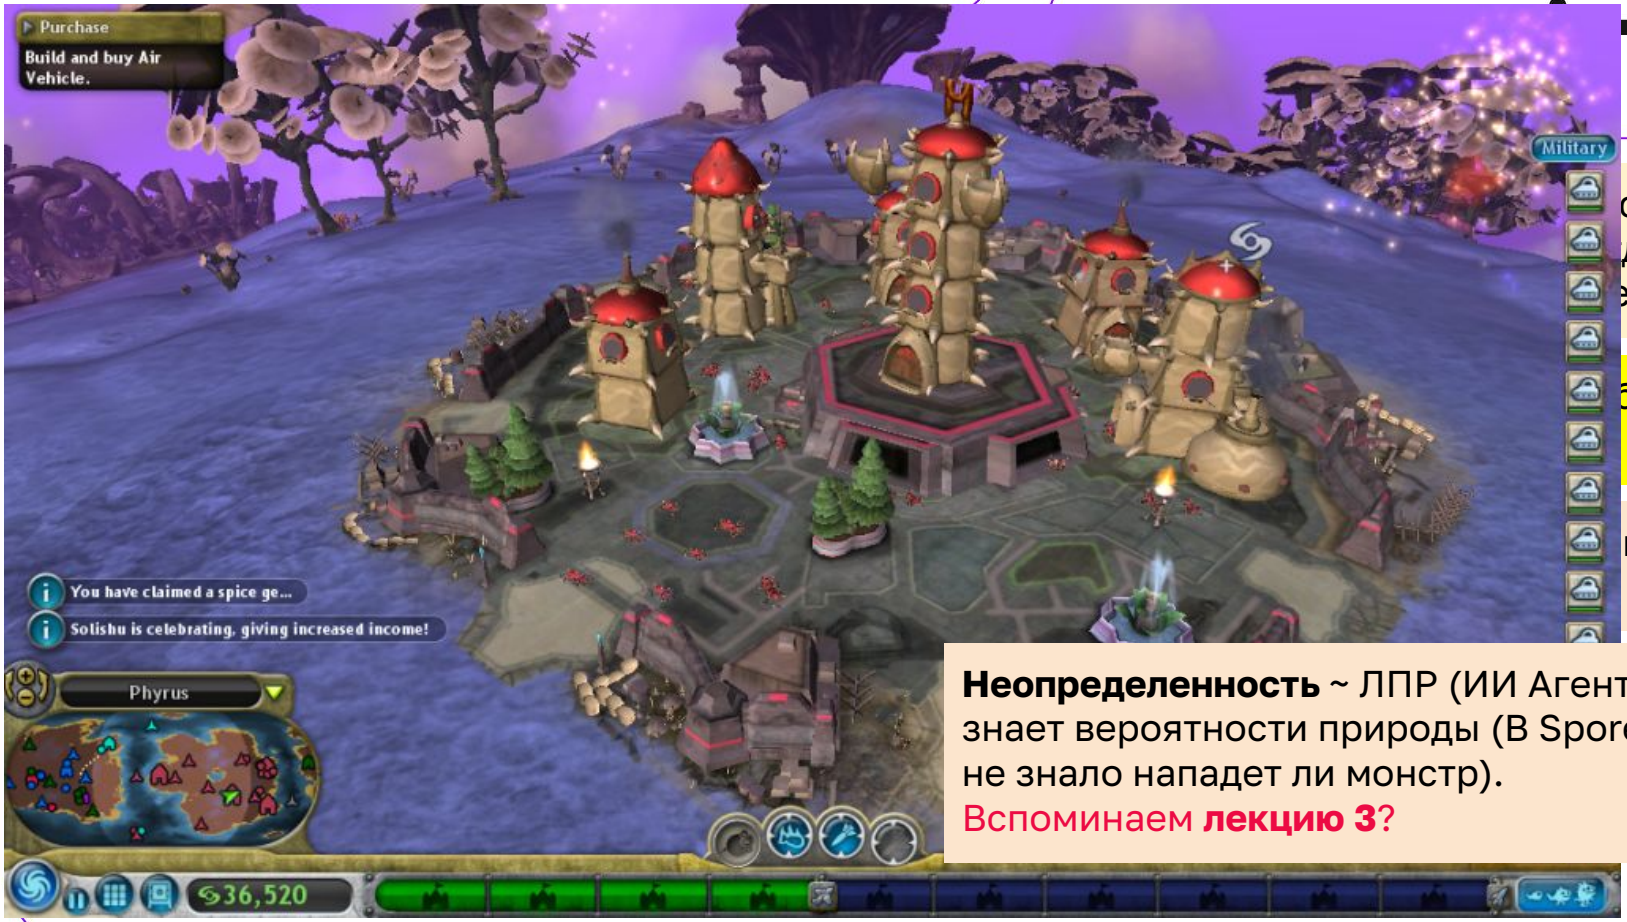
Об Исследовании операций от System Lab

тмо

собой
дение
ебора.

бя

ция.



Неопределенность ~ ЛПР (ИИ Агент) не знает вероятности природы (В Spore ЛПР не знало нападет ли монстр).
Вспоминаем **лекцию 3**?

*Черноиванова Е.А. Курс лекций “Исследование операций и методы оптимизации”

Об Исследовании операций от System Lab

ГЛАВА 4 _ Принятие решений

Теория принятия оптимальных решений* в наиболее общем смысле представляет собой совокупность математических и численных методов, ориентированных на нахождение наилучших вариантов из множества альтернатив и позволяющих избежать их полного перебора.

Теория принятия решений – обширное научное направление, которое включает в себя существенную часть методологии исследования операций и системного анализа.



Определенность ~ полная информация. Вспоминаем **лекцию 1**.

Неопределенность ~ ЛПР (ИИ Агент) не знает вероятности природы (В Spore ЛПР не знало нападет ли монстр). Вспоминаем **лекцию 3**?

Риск ~ ЛПР знает вероятности природы

*Черноиванова Е.А. Курс лекций “Исследование операций и методы оптимизации”

Об Исследовании операций от System Lab

ГЛАВА 4 _ Принятие решений

Теория принятия оптимальных решений* в наиболее общем смысле представляет собой совокупность математических и численных методов, ориентированных на нахождение наилучших вариантов из множества альтернатив и позволяющих избежать их полного перебора.

Теория принятия решений — обширное научное направление, которое включает в себя существенную часть методологии исследования операций и системного анализа.

Риск ~ ЛПР знает вероятности природы

В условиях риска. Известно распределение вероятностей всех состояний природы и для выбора оптимального решения применяют критерии:

- Максимизация ожидаемого результата, выраженного в виде платежей.
- Минимизация ожидаемых потерь.
- Максимизация ожидаемого результата, выраженного в виде значения полезности.

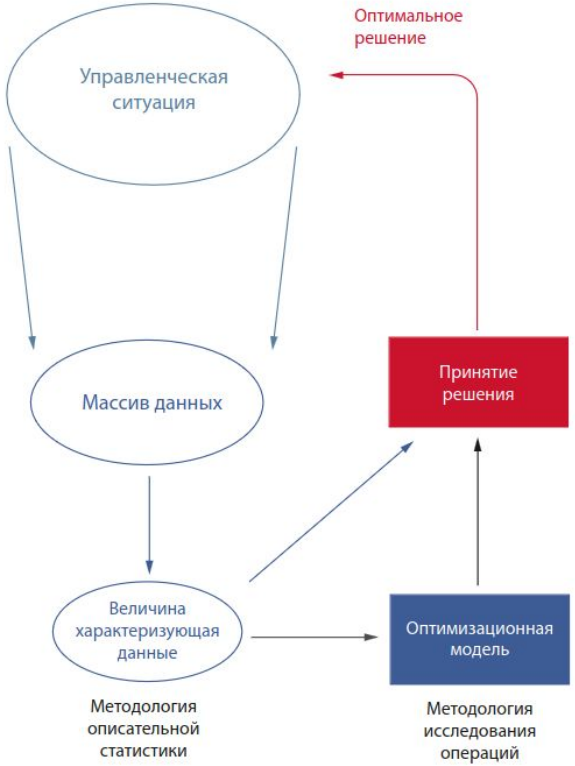
*Черноиванова Е.А. Курс лекций “Исследование операций и методы оптимизации”

Об Исследовании операций от System Lab

ГЛАВА 4 _ Принятие решений

Теория принятия оптимальных решений* в наиболее общем смысле представляет собой совокупность математических и численных методов, ориентированных на нахождение наилучших вариантов из множества альтернатив и позволяющих избежать их полного перебора.

Теория принятия решений – обширное научное направление, которое включает в себя существенную часть методологии исследования операций и системного анализа.



*Черноиванова Е.А. Курс лекций “Исследование операций и методы оптимизации”

Об Исследовании операций от System Lab

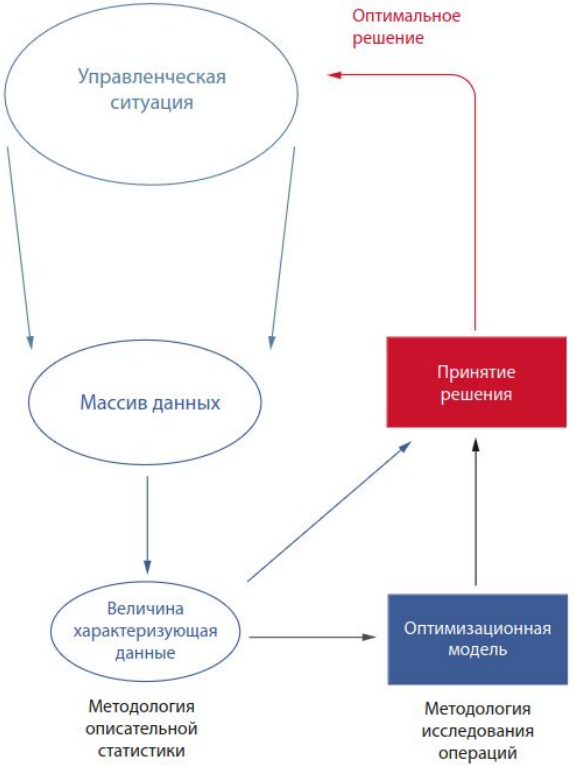
ГЛАВА 4 _ Принятие решений

(Математическая)
Теория оптимизации



Исследование операций

Теория принятия решений

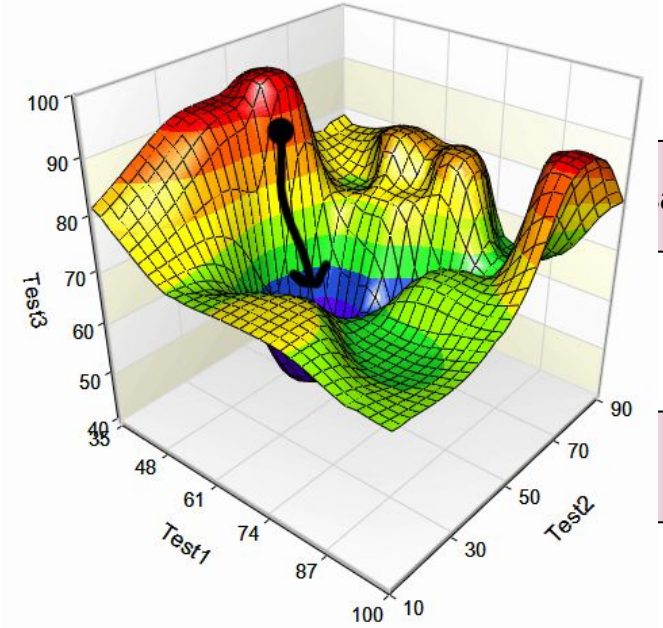


Об Исследовании операций от System Lab

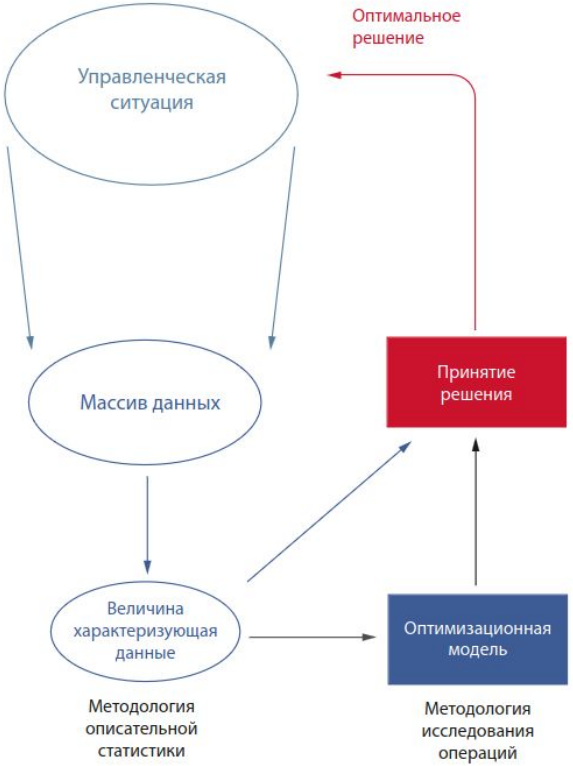
ГЛАВА 4 _ Принятие решений

ИТМО

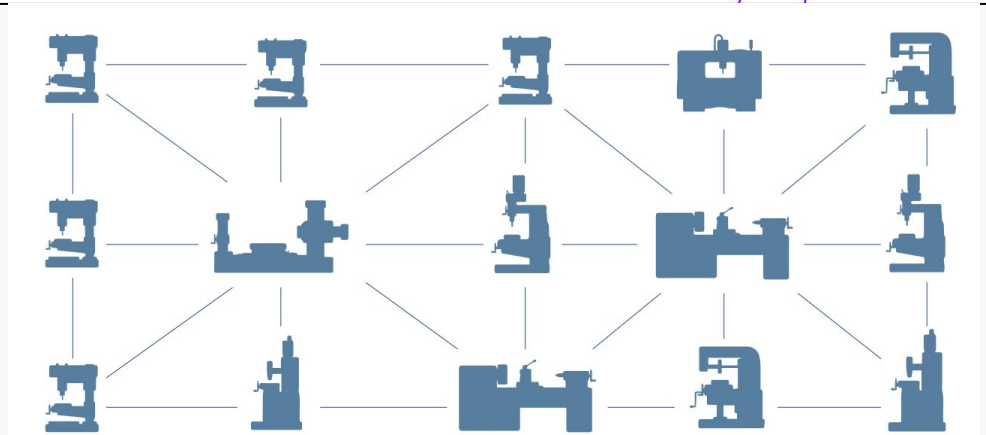
(Математическая)
Теория оптимизации



ание операций

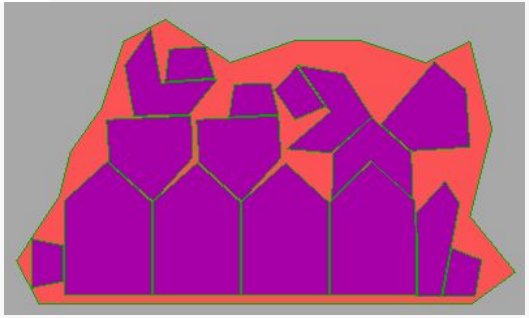


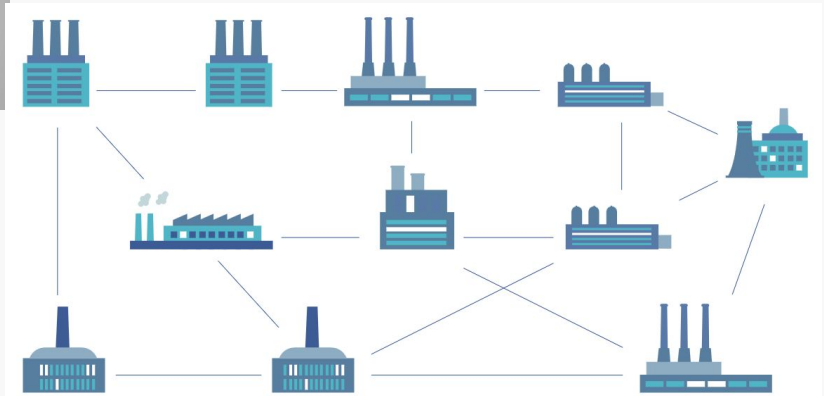
Об Исследовании операций от System Lab





Исследование операций



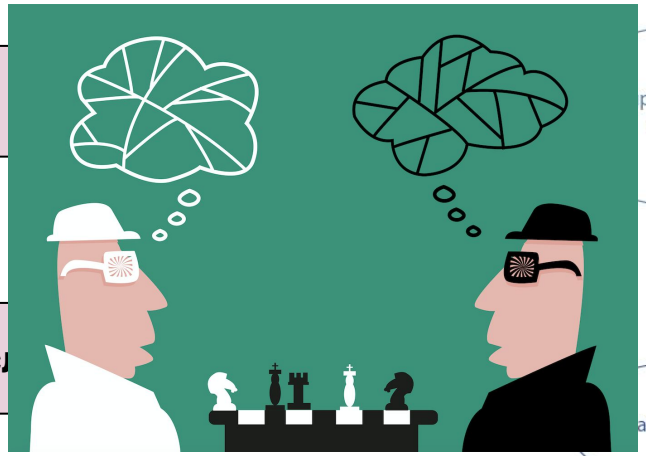


ГЛАВА 4 _ Принятие решений

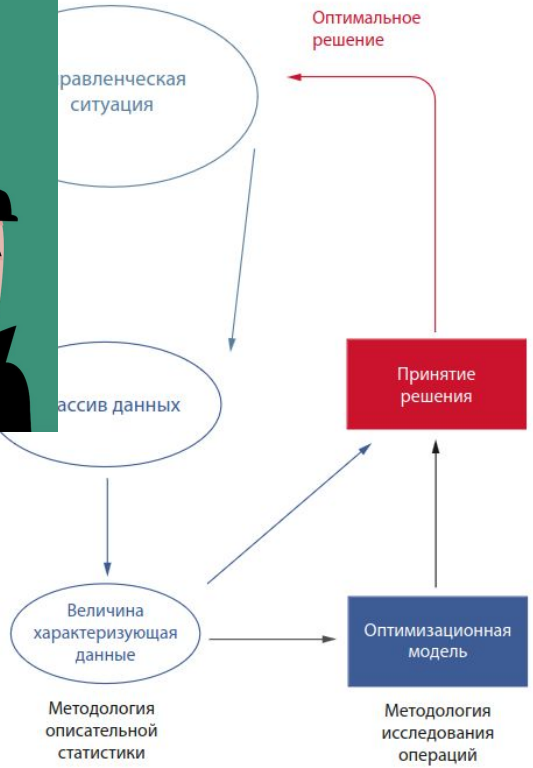
ИТМО

(Математическая) Теория оптимизации





Теория принятия решений



Об Исследовании операций от System Lab

ГЛАВА 4 _ Принятие решений



Об Исследовании операций от System Lab

ГЛАВА 4 _ Теория полезности

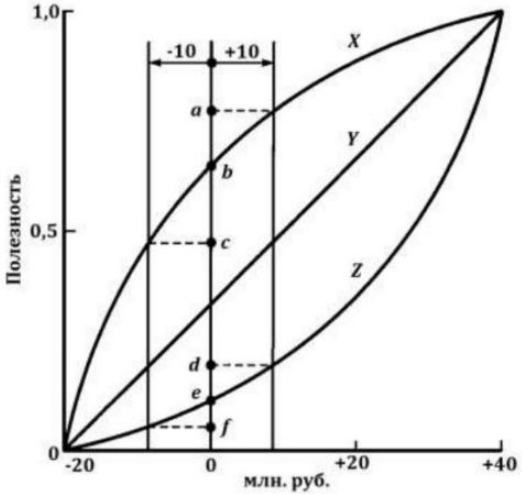
Теория полезности рассматривает вопросы построения процедур для определения предпочтений в количественной форме.

Полезность, *в нашем случае*, это количественная оценка, когда мы в виде числа выражаем предпочтение ЛПР, пытаясь отразить его сравнительную природу.

Полезность может измерять что угодно - от наблюдаемых объективных данных (например, здоровье противника) до субъективных понятий, таких как эмоции, настроение и угроза. Различные полезные сведения о возможных действиях или решениях могут быть объединены в линейные или нелинейные формулы и направлять агента к принятию решений на основе агрегированной полезной информации. (AI & Games book)

Майзер Х., Эйджин Н., Тролл Р. и др. “Исследование операций” в 2 томах. Т1: “Методологические основы и математические методы”, 792 стр., 1978

ГЛАВА 4 _ Теория полезности



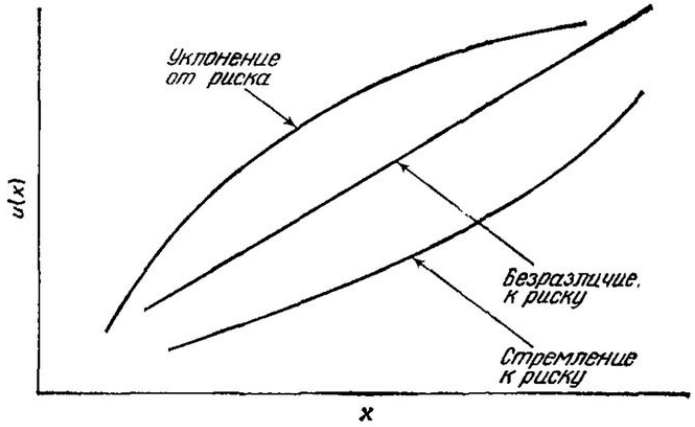


Рис. 4. Отношение к риску.

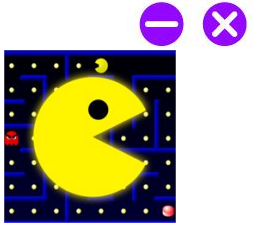
1) предварительный анализ для фактической оценки;
2) определение соответствующих качественных параметров;
3) формирование количественных ограничений;
4) выбор функции полезности;
5) проверка на согласованность.

Майзер Х., Эйджин Н., Тролл Р. и др. “Исследование операций” в 2 томах. Т1: “Методологические основы и математические методы”, 792 стр., 1978

ГЛАВА 4 _ Utility AI

ИТМО

Нужна **информация** → Вычисляем **полезность** → Производим **действие** с максимальной полезностью



Отличная презентация от исследователя ИИ в играх про Полезность

ГЛАВА 4 _ Utility AI

ИТМО

Нужна **информация** → Вычисляем **полезность** → Производим **действие** с максимальной полезностью



Охота на призраков	Если режим таблетки, то полезность = 100, иначе 0
Сбор очков	Если призрак “далеко”, то полезность = 75, иначе 25
Убежать	Если призрак “близко”, то полезность = 100, иначе 10

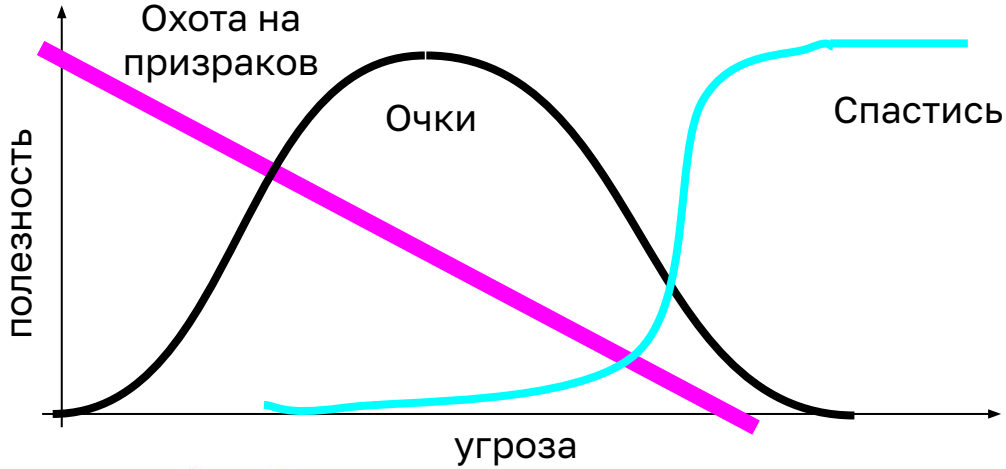
Отличная презентация от исследователя ИИ в играх про полезность

ГЛАВА 4 _ Utility AI

ИТМО

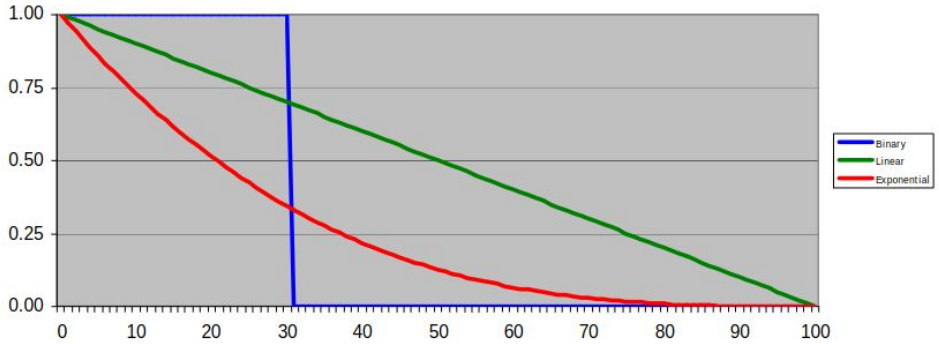
Нужна **информация** → Вычисляем **полезность** → Производим **действие** с максимальной полезностью

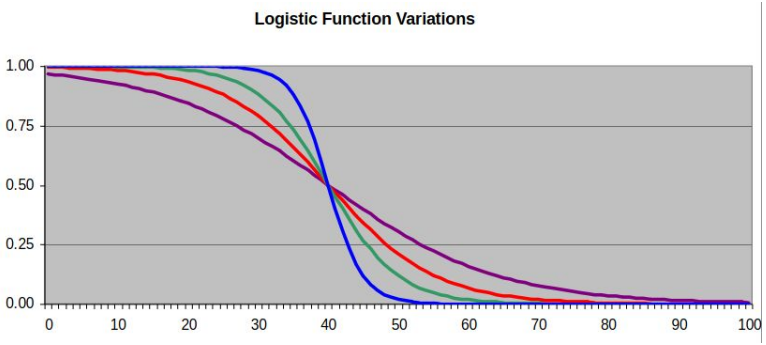


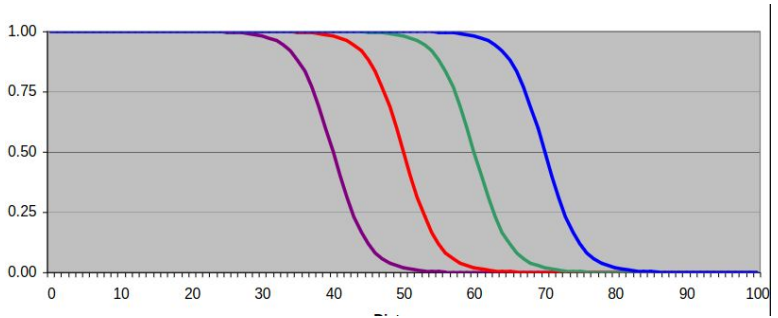


Отличная презентация от исследователя ИИ в играх про Полезность

ГЛАВА 4 _ Utility AI



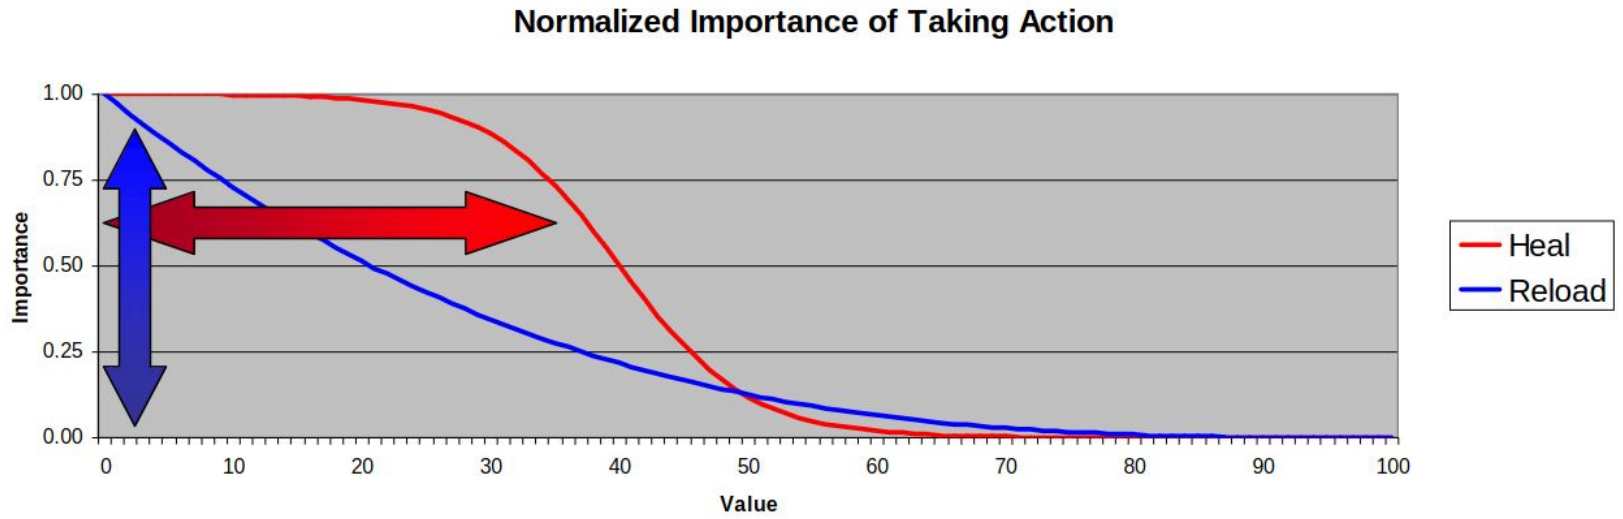




Отличная презентация от исследователя ИИ в играх про полезность

ГЛАВА 4 _ Utility AI

ИТМО

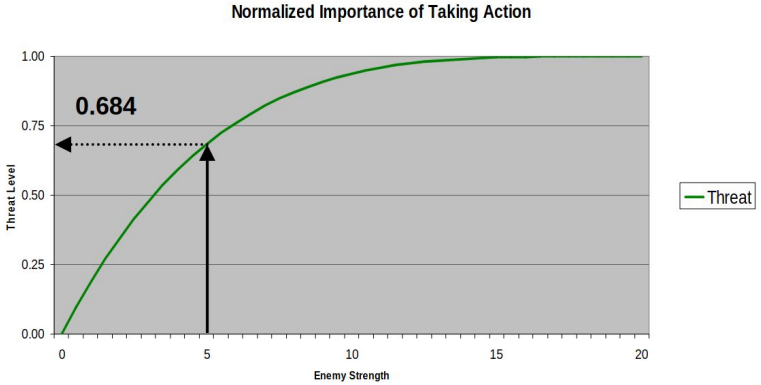


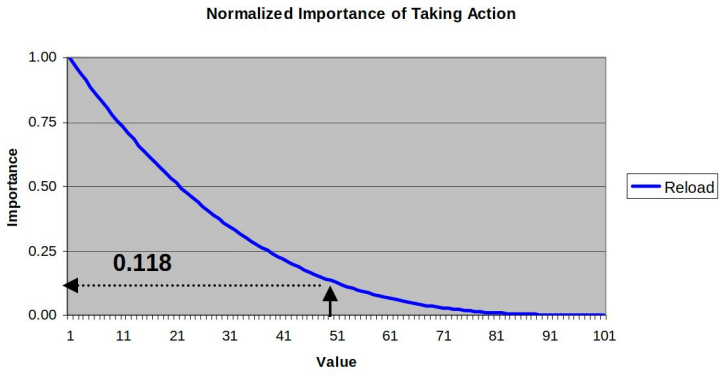
Отличная презентация от исследователя ИИ в играх про полезность

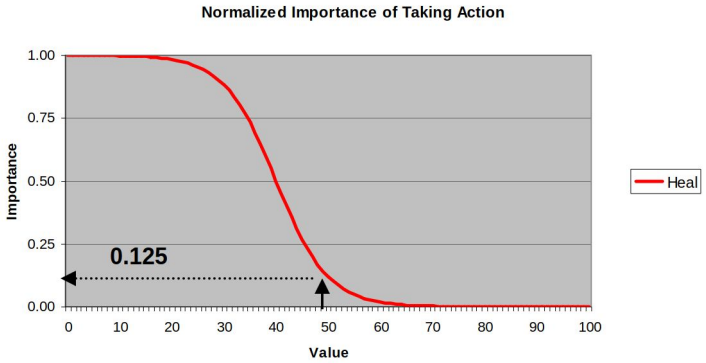
ГЛАВА 4 _ Utility AI

ИТМО

	Enemies	Ammo	Health
Value	5	50	50
Utility	0.684	0.118	0.125







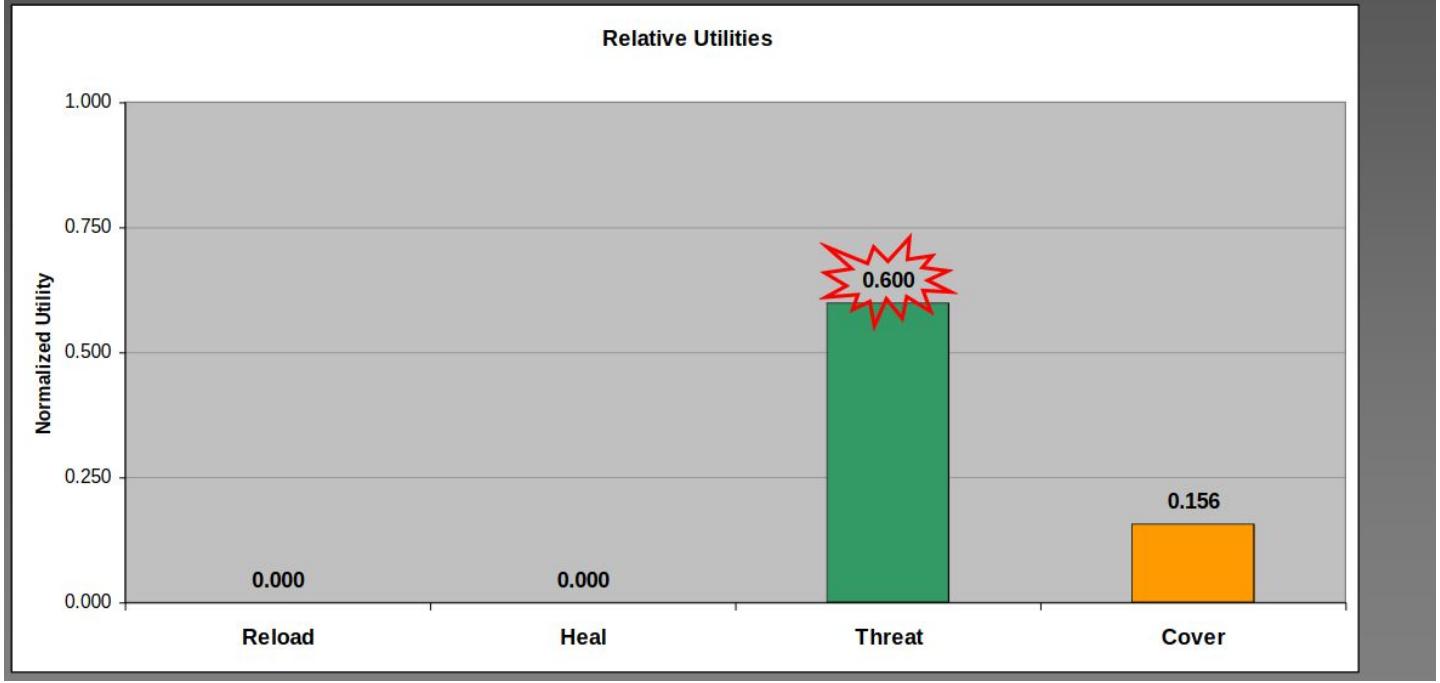
Отличная презентация от исследователя ИИ в играх про полезность

Вопрос: Всегда ли мы можем принять решение на основе только одного фактора? Как объединить факторы?

ГЛАВА 4 _ Utility AI

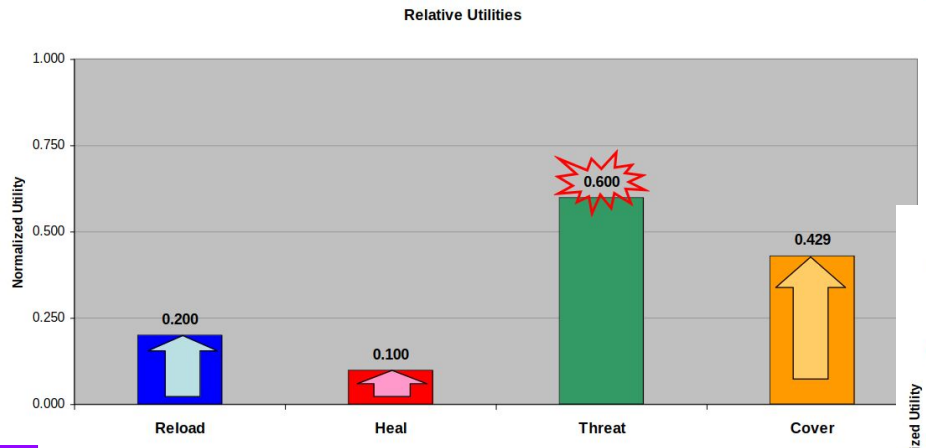
ИТМО

Cover = (0.2 + Reload + (Heal x 1.5)) x (Threat x 1.3)

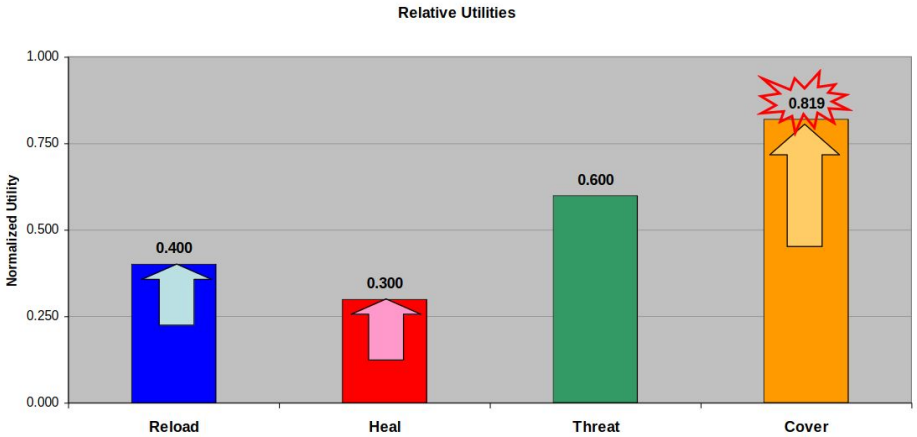


Отличная презентация от исследователя ИИ в играх про полезность

ГЛАВА 4 _ Utility AI



(0.2 + 0.2 + 0.15) * (0.78) = 0.429

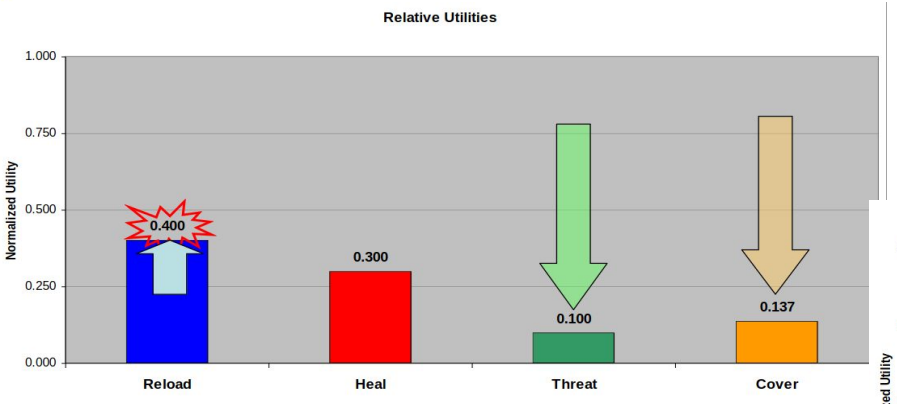


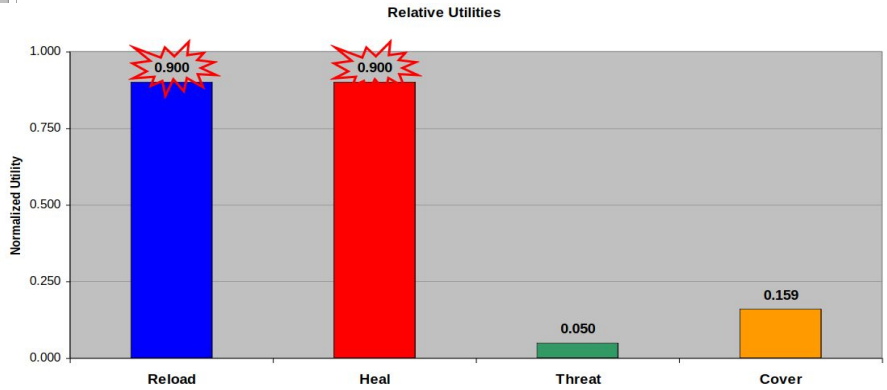
Cover = (0.2 + Reload + (Heal x 1.5)) x (Threat x 1.3)

Отличная презентация от исследователя ИИ в играх про полезность

ГЛАВА 4 _ Utility AI

ИТМО

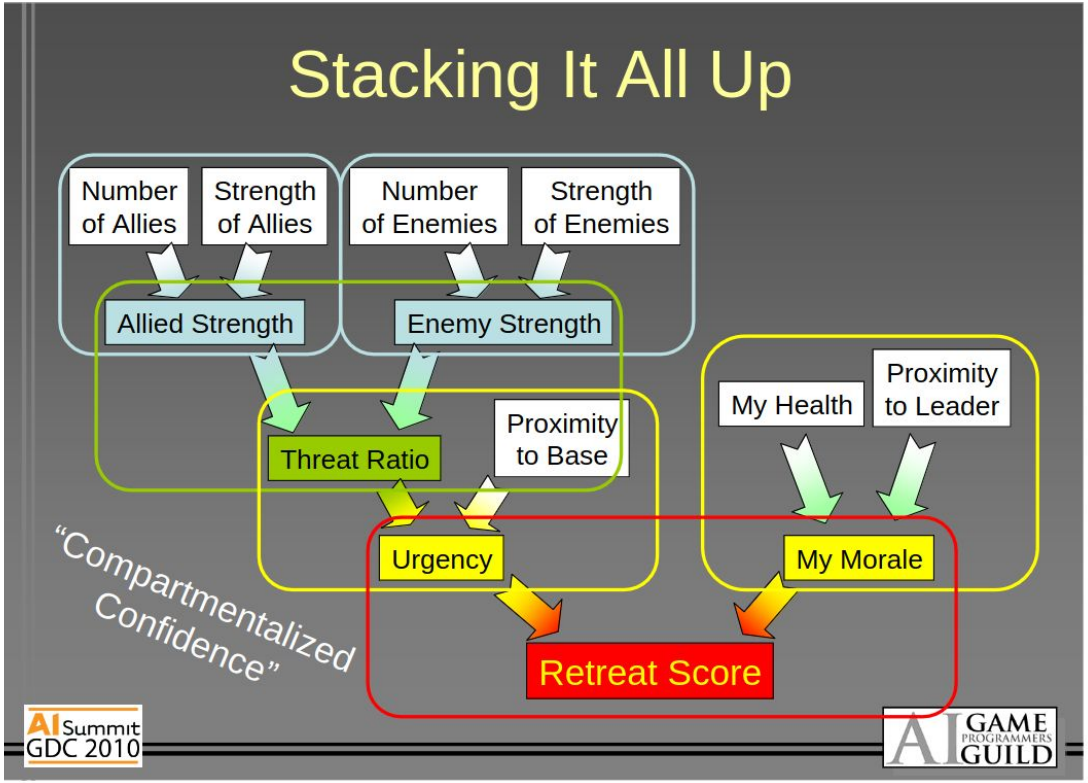




Cover = (0.2 + Reload + (Heal x 1.5)) x (Threat x 1.3)

Отличная презентация от исследователя ИИ в играх про полезность

ИТМО

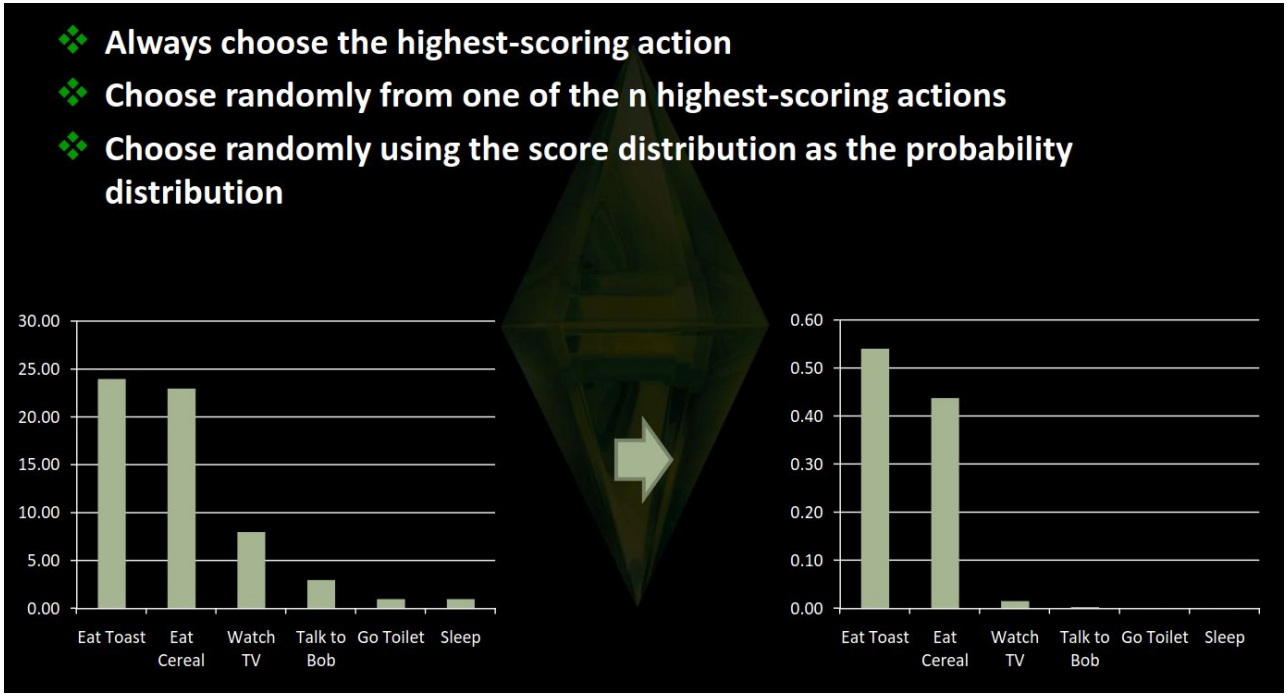


Отличная презентация от исследователя ИИ в играх про полезность

Вопрос: А всегда ли хорошо выполнять действия по максимуму полезности?

ГЛАВА 4 _ Utility AI

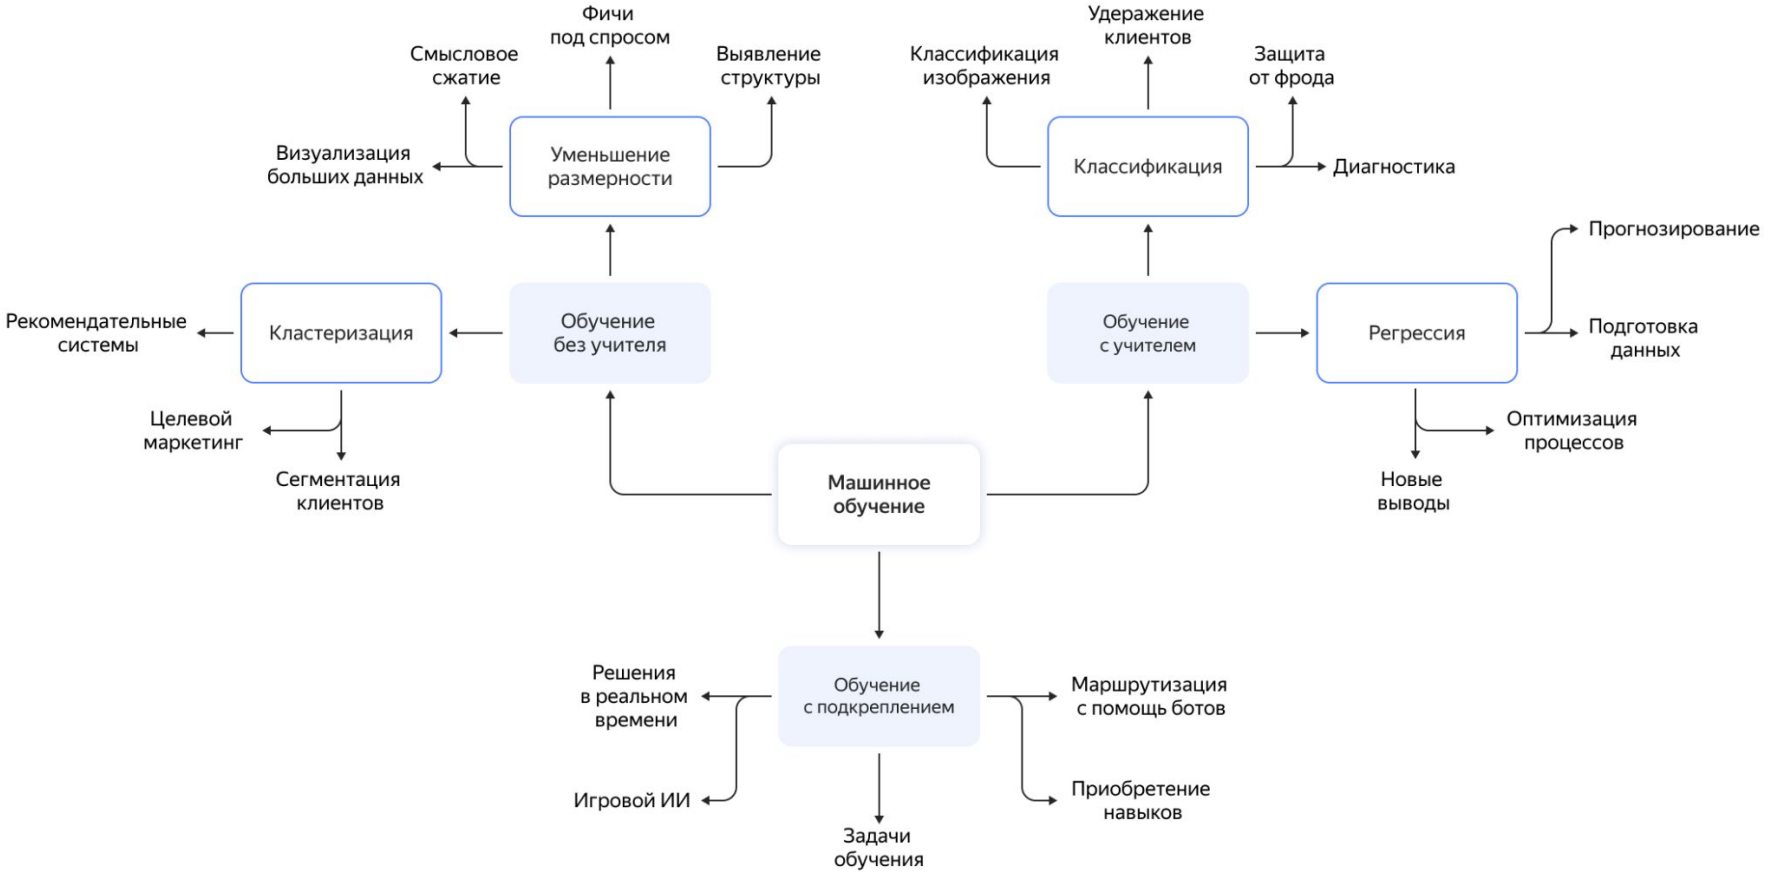
ИТМО



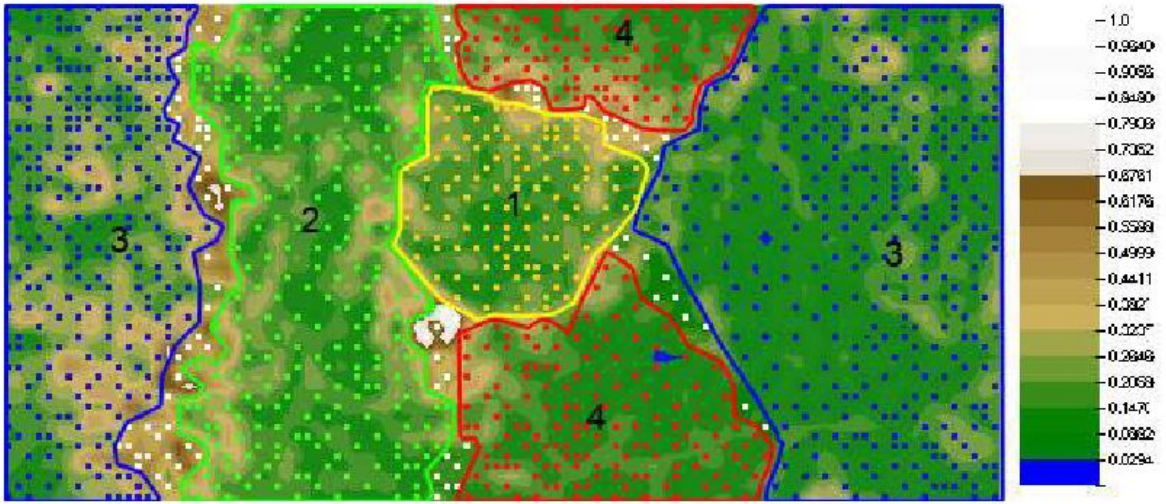
Организация ИИ в Sims 3

Отличная презентация от исследователя ИИ в игре про полезность

ГЛАВА 4 _ Машинное обучение



ГЛАВА 4 _ Машинное обучение



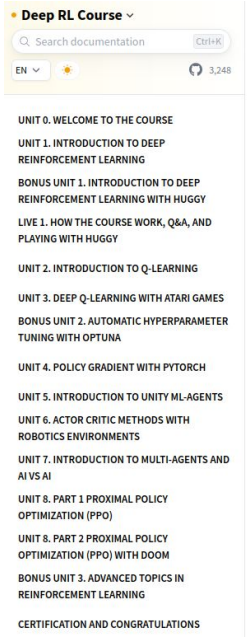
(b) U-matrix visualization of a self-organizing map depicting the four player clusters identified in a population of 1,365 TRU players (shown as small colored squares). Different square colors depict different player clusters. Valleys represent clusters whereas mountains represent cluster borders. Image adopted from [176].

Пример кластеризации
(AI and Games, 2018, p.241)

https://huggingface.co/learn/ml-games-course/unit0/introduction

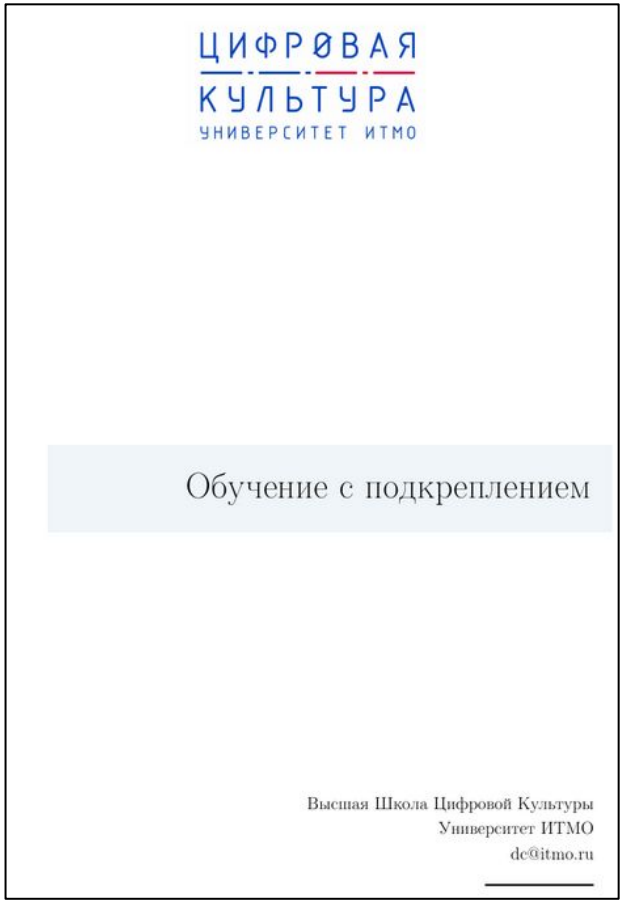
ГЛАВА 4 _ Обучение с подкреплением

Основные источники

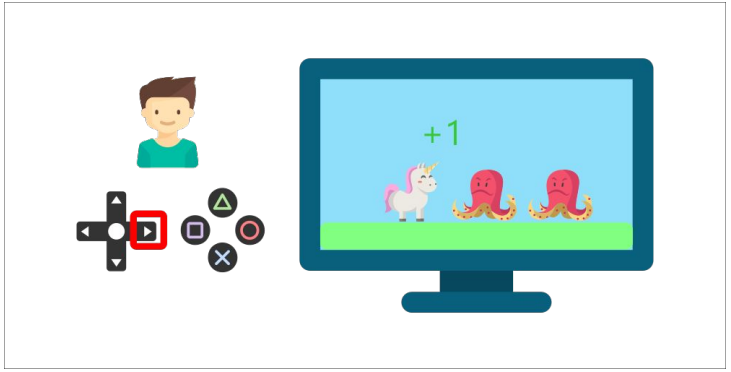


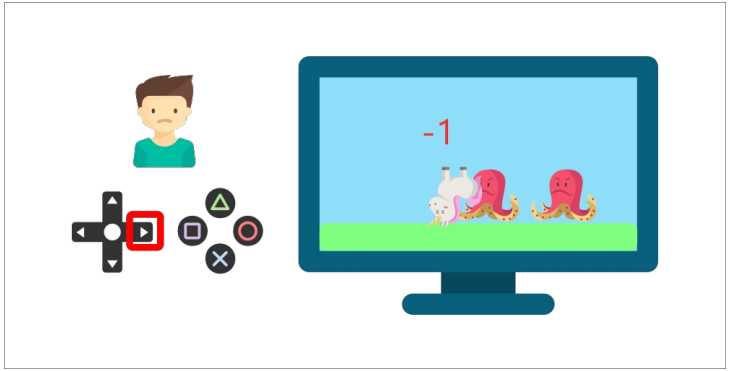


Deep RL Course (huggingface)



ГЛАВА 4 _ Обучение с подкреплением





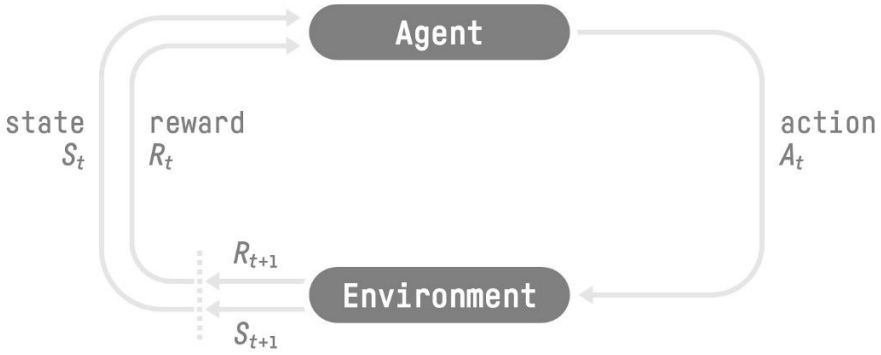
Обучение с подкреплением это всего лишь вычислительный подход к обучению через взаимодействие со средой (environment).

Обучение с подкреплением это инструмент для решения задач управления (задач принятия решений) через построение агентов, которые учатся на основе проб и ошибок, взаимодействуя со средой, и получают награды (положительные и отрицательные) как обратную связь.

> Reinforcement learning is a framework for solving control tasks (also called decision problems) by building agents that learn from the environment by interacting with it through trial and error and receiving rewards (positive or negative) as unique feedback.

Deep RL Course (huggingface)

ГЛАВА 4 _ Обучение с подкреплением







Почему целью агента является максимизация ожидаемой прибыли?

Потому что RL основан на **гипотезе вознаграждения**, которая заключается в том, что все цели могут быть описаны как максимизация ожидаемой отдачи (ожидаемое кумулятивное вознаграждение).

Вот почему при обучении с подкреплением, чтобы добиться наилучшего поведения, мы стремимся научиться предпринимать действия, которые максимизируют ожидаемое совокупное вознаграждение.

Deep RL Course (huggingface)

ГЛАВА 4 _ Обучение с подкреплением

Observation Space

State: **complete description** of the state of the world (no hidden information).



Observation: **partial description** of the state of the world.



Action Space

Discrete: **finite number of possible actions**



Continuous: **infinite number of possible actions**



Deep RL Course (huggingface)

ГЛАВА 4 _ Обучение с подкреплением

Кумулятивное вознаграждение на каждом временном шаге t может быть записано как:

$$R(\tau) = r_{t+1} + r_{t+2} + r_{t+3} + r_{t+4} + \dots$$

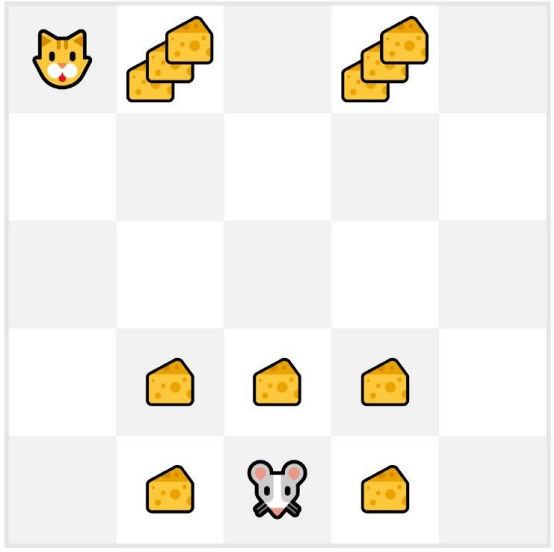
Return: cumulative reward

Trajectory (read Tau)
Sequence of states and actions

$$R(\tau) = \sum_{k=0}^{\infty} r_{t+k+1}$$

ГЛАВА 4 _ Обучение с подкреплением

Однако на самом деле мы не можем просто добавить их таким образом. Награды, которые приходят раньше (в начале игры), с большей вероятностью произойдут, поскольку они более предсказуемы, чем долгосрочное будущее вознаграждение.

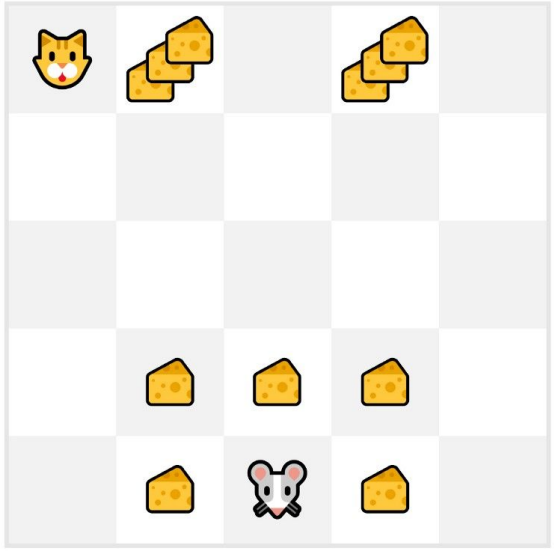


Как мы можем видеть на карте, более вероятно съесть сыр рядом с нами, чем сыр рядом с кошкой (чем ближе мы к кошке, тем это опаснее).

Следовательно, награда рядом с кошкой, даже если она больше (больше сыра), будет более дешевой, поскольку мы на самом деле не уверены, что сможем ее съесть.

ГЛАВА 4 _ Обучение с подкреплением

Однако на самом деле мы не можем просто добавить их таким образом. Награды, которые приходят раньше (в начале игры), с большей вероятностью произойдут, поскольку они более предсказуемы, чем долгосрочное будущее вознаграждение.



Скидка на вознаграждения:

1. Ставка дисконтирования (какова скидка)
   0~1 (как правило 0.95~0.99)
2. Каждое последующее дисконтирование по ставке по временному шагу.

$$R(\tau) = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \gamma^3 r_{t+4} + \dots$$

Return: cumulative reward

Gamma: discount rate

Trajectory (read Tau)
Sequence of states and actions

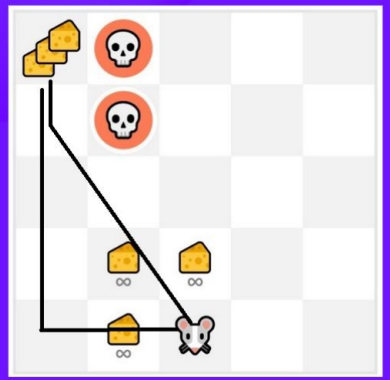
$$R(\tau) = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

Deep RL Course (huggingface)

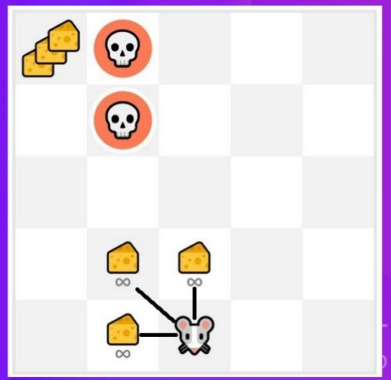
Про вознаграждения

Exploration/ Exploitation tradeoff

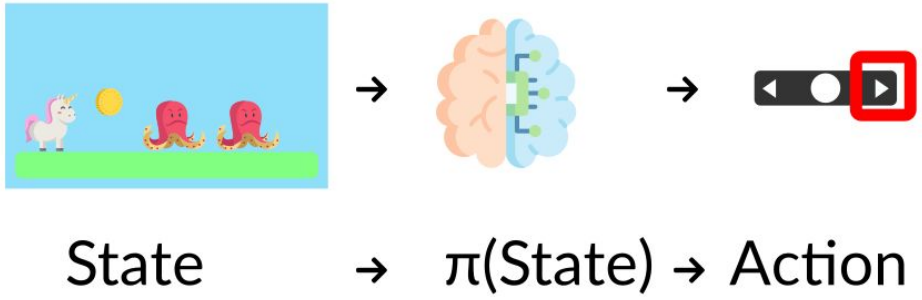
Exploration: trying **random actions** in order to find **more information about the environment.**



Exploitation: using known information to **maximize the reward.**



ГЛАВА 4 _ Обучение с подкреплением



Существует два подхода к обучению нашего агента поиску этой оптимальной политики (стратегии) π *:

1. Непосредственно, обучая агента тому, какие действия следует предпринять, учитывая текущее состояние: **Policy-Based Methods**.
2. Косвенно обучая агента узнавать, какое состояние является более ценным, а затем предпринимать действия, которые приводят к более ценным состояниям: **Value-Based Methods**.

Deep RL Course (huggingface)

Как решать?

ГЛАВА 4 _ Обучение с подкреплением

ИТМО

Policy-Based Methods

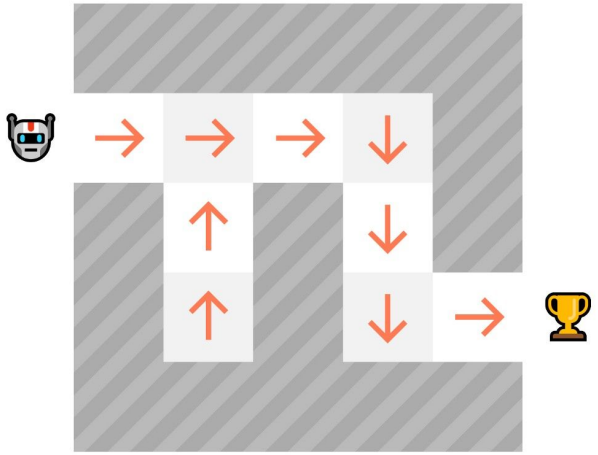
Deterministic: a policy at a given state **will always return the same action.**

$$a = \pi(s)$$



State s_0 → $\pi(s_0)$ → a_0 = Right

Deep RL Course



Stochastic: output a **probability distribution over actions.**

$$\pi(a|s) = P[A|s]$$

Probability Distribution over the set of actions given the state



State s_0 → $\pi(A|s_0)$ → [Left: 0.1, Right: 0.7, Jump: 0.2]

Deep RL Course

Как решать?

Policy Based

Deep RL Course (huggingface)

ГЛАВА 4 _ Обучение с подкреплением

ИТМО

Value-Based Methods

The value of a state is the **expected discounted return** the agent can get if it **starts in that state, and then act according to our policy.**

$$v_\pi(s) = \mathbb{E}_\pi\left[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots \mid S_t = s\right]$$

Value function — Expected discounted return — Starting at state s

"Act according to our policy" just means that our policy is **"going to the state with the highest value".**

Deep RL Course



Value Based

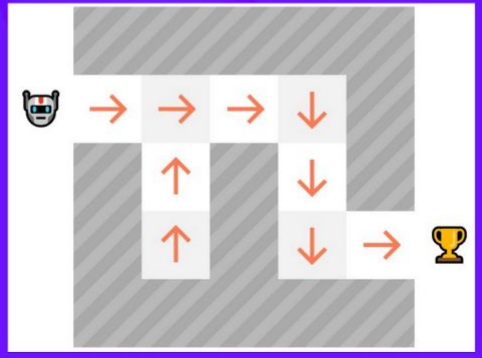
Как решать?

Deep RL Course (huggingface)

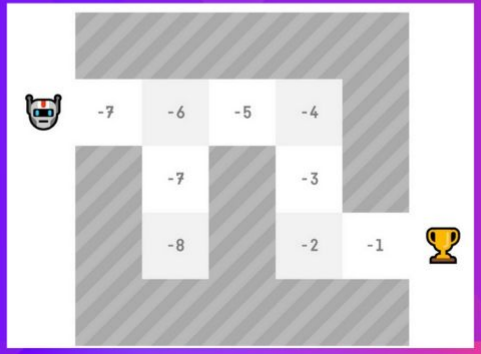
ГЛАВА 4 _ Обучение с подкреплением

Two approaches to find optimal policy π^*:

***Policy-Based methods*:** train the agent to learn which **action to take,** given a state.



***Value-Based methods*:** train the agent to learn which state **is more valuable** and take the action that **leads to it.**



Deep RL Course (huggingface)

Как решать?

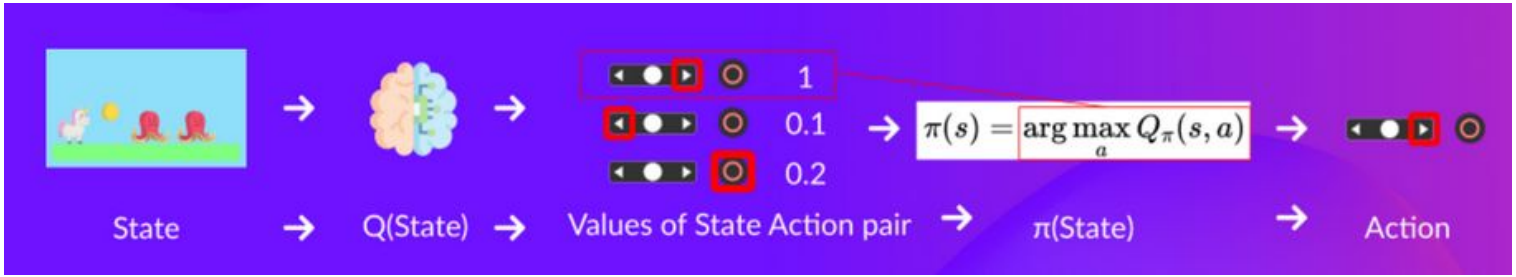
ГЛАВА 4 _ Обучение с подкреплением

Policy-based method:
- Обучаем саму “политику”

Value-based method:
- Обучаем функцию значений

Связь между методами:

$$\pi^*(s) = \arg\max_a Q^*(s, a)$$

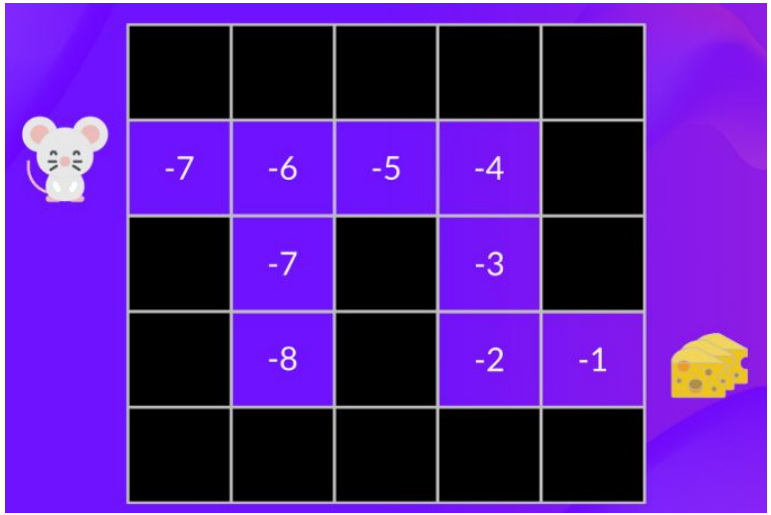


Deep RL Course (huggingface)

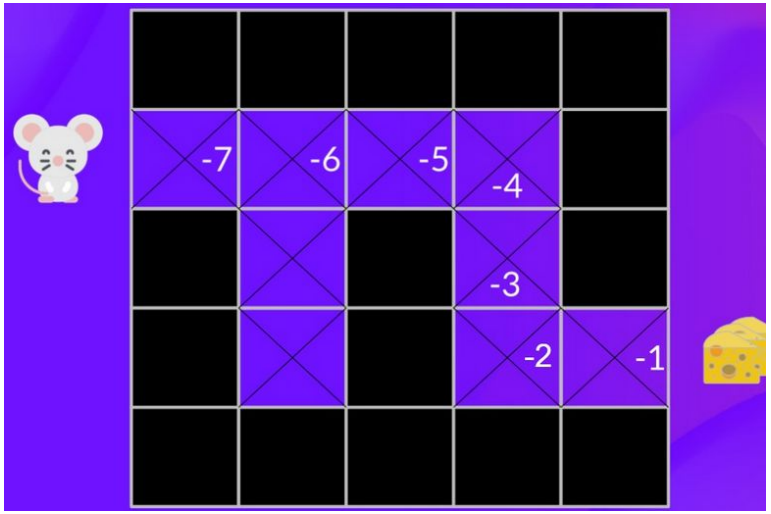
ГЛАВА 4 _ Обучение с подкреплением

Существуют два основных value-based подхода:

Функция состояние-значение:



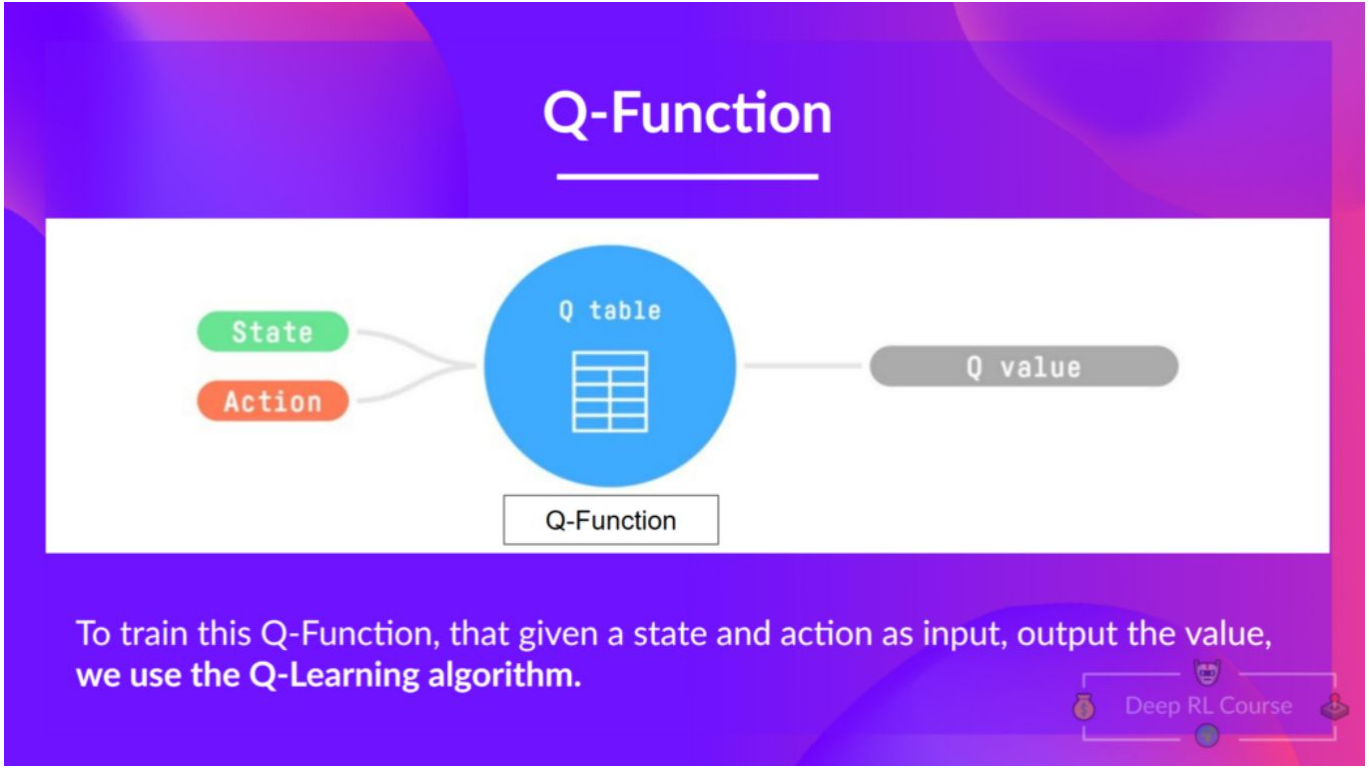
Функция действие-значение:



Deep RL Course (huggingface)

ГЛАВА 4 _ Q-learning

ИТМО



ГЛАВА 4 _ Q-learning

ИТМО

- **Value состояния или пары состояние-действие** - это ожидаемое совокупное вознаграждение, которое получает наш агент, если он запускается в этом состоянии (или паре состояние-действие) и затем действует в соответствии со своей политикой.
- **Вознаграждение** - это обратная связь, которую агент получает от среды после выполнения действия в состоянии.

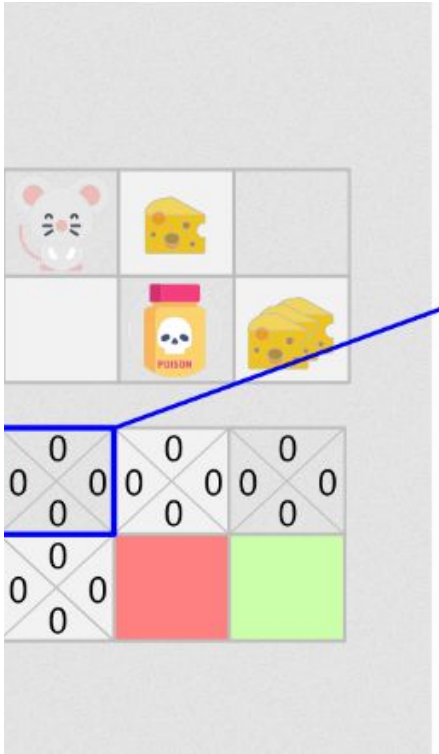


	←	→	↑	↓
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0

Q-таблица

ГЛАВА 4 _ Q-learning

ИТМО



Actions

States

	←	→	↑	↓
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0

Deep RL Course (huggingface)

ГЛАВА 4 _ Q-learning

ИТМО

В общем, **Q-Learning** - это алгоритм RL, который:

- Обучает Q-функцию (функцию действия-значения), которая внутренне представляет собой Q-таблицу, содержащую все значения пары состояние-действие.
- Учитывая состояние и действие, наша Q-функция выполнит поиск соответствующего значения в своей Q-таблице.
- По завершении обучения у нас будет оптимальная Q-функция, что означает, что у нас есть оптимальная Q-таблица.
- И если у нас есть оптимальная Q-функция, то у нас есть оптимальная политика, поскольку мы знаем, какие действия лучше всего предпринять в каждом состоянии.

$$\pi^*(s) = \arg\max_a Q^*(s, a)$$

Deep RL Course (huggingface)

ГЛАВА 4 _ Q-learning

ИТМО

Algorithm 14: Sarsamax (Q-Learning)

Input: policy π, positive integer *num_episodes*, small positive fraction α, GLIE $\{\epsilon_i\}$
Output: value function Q ($\approx q_\pi$ if *num_episodes* is large enough)
Initialize Q arbitrarily (e.g., $Q(s,a) = 0$ for all $s \in \mathcal{S}$ and $a \in \mathcal{A}(s)$, and $Q(\textit{terminal-state}, \cdot) = 0$)
for $i \leftarrow 1$ ***to*** *num_episodes* **do** Step 1
  $\epsilon \leftarrow \epsilon_i$
  Observe S_0
  $t \leftarrow 0$
  repeat
    Choose action A_t using policy derived from Q (e.g., ϵ-greedy) Step 2
    Take action A_t and observe R_{t+1}, S_{t+1} Step 3
    $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha(R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t))$ Step 4
    $t \leftarrow t + 1$
  until S_t *is terminal*;
end
return Q

Deep RL Course (huggingface)

ГЛАВА 4 _ Q-learning

ИТМО

Initialize Q arbitrarily (e.g., $Q(s, a) = 0$ for all $s \in \mathcal{S}$ and $a \in \mathcal{A}(s)$, and $Q(terminal\text{-}state, \cdot) = 0$)

	←	→	↑	↓
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0

Deep RL Course (huggingface)

Инициализация

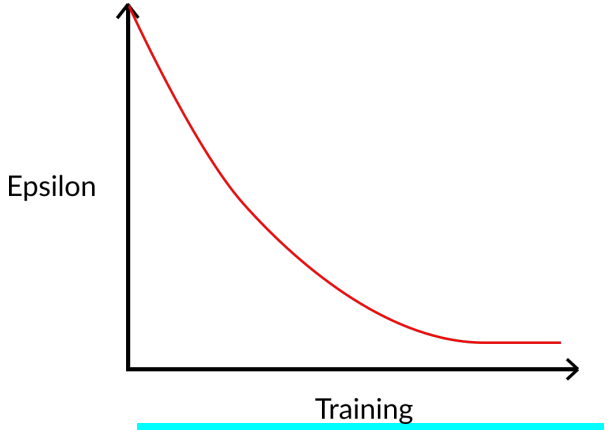
ГЛАВА 4 _ Q-learning

ИТМО

Choose action A_t using policy derived from Q (e.g., ϵ-greedy)

Используя **эпсилон-жадную** политику выбираем следующее действие A:

1. Генерируем случайное число от 0 до 1.
2. С вероятностью **эпсилон** - агент исследует (**exploration**) мир (выбирает случайное действие)
3. С вероятностью (**1 - эпсилон**) - агент использует накопленные знания (**exploitation**), то есть выбирает действие жадно.



Выбор действия

ГЛАВА 4 _ Q-learning

ИТМО

Take action A_t and observe R_{t+1}, S_{t+1}

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[R_{t+1} + \gamma max_a Q(S_{t+1}, a) - Q(S_t, A_t)]$$

New Q-value estimation

Former Q-value estimation

Learning Rate

Immediate Reward

Discounted Estimate optimal Q-value of next state

Former Q-value estimation

Deep RL Course (huggingface)

Исследуем и обновляем

ГЛАВА 4 _ Q-learning

ИТМО

Algorithm 14: Sarsamax (Q-Learning)

Input: policy π, positive integer *num_episodes*, small positive fraction α, GLIE $\{\epsilon_i\}$
Output: value function Q ($\approx q_\pi$ if *num_episodes* is large enough)
Initialize Q arbitrarily (e.g., $Q(s,a) = 0$ for all $s \in \mathcal{S}$ and $a \in \mathcal{A}(s)$, and $Q(\textit{terminal-state}, \cdot) = 0$)
for $i \leftarrow 1$ ***to*** *num_episodes* **do** Step 1
  $\epsilon \leftarrow \epsilon_i$
  Observe S_0
  $t \leftarrow 0$
  repeat
    Choose action A_t using policy derived from Q (e.g., ϵ-greedy) Step 2
    Take action A_t and observe R_{t+1}, S_{t+1} Step 3
    $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha(R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t))$ Step 4
    $t \leftarrow t + 1$
  until S_t *is terminal*;
end
return Q

Deep RL Course (huggingface)

ГЛАВА 4 _ Q-learning

ИТМО



	←	→	↑	↓
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0

1) Всегда стартуем с одной точки
2) Цель съесть большой кусок сыра и избегать яда
3) learning_rate = 0.1
4) gamma = 0.99

+0: на клетку без всего
+ 1: съел маленький кусок сыра
+10: съел большой кусок сыра
-10: съел яд
+0: для любого действия, если ужы было совершено 5 действий

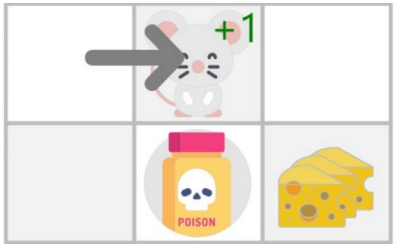
Deep RL Course (huggingface)

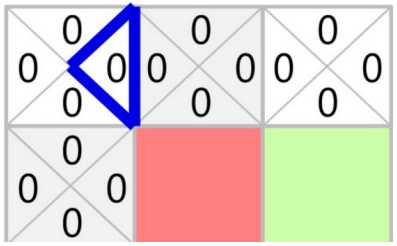
Пример

ГЛАВА 4 _ Q-learning

ИТМО

Выбираем действие (эпсилон = 1)





R[t+1] = 1 - агент съел маленький кусок сыра

	←	→	↑	↓
	0	0.1	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0

Обновляем Q(St, At)
Q(Q[0], right) = 0 + 0.1*(1 + 0.99*0 - 0)
Q(Q[0], right) = 0.1

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha(R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t))$$

Deep RL Course (huggingface)

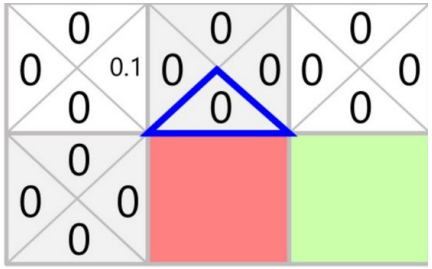
Пример

ГЛАВА 4 _ Q-learning

ИТМО

Выбираем действие (эпсилон = 1)





	←	→	↑	↓
	0	0.1	0	0
	0	0	0	-1
	0	0	0	0
	0	0	0	0
	0	0	0	0
	0	0	0	0

R[t+1] = -10 - агент съел яд (конечный state)

Обновляем Q(St, At)
Q(Q[1], down) = 0 + 0.1*(-10 + 0.99*0 - 0)
Q(Q[1], down) = -1

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha(R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t))$$

Deep RL Course (huggingface)

Пример

ГЛАВА 4 _ Q-learning

ИТМО

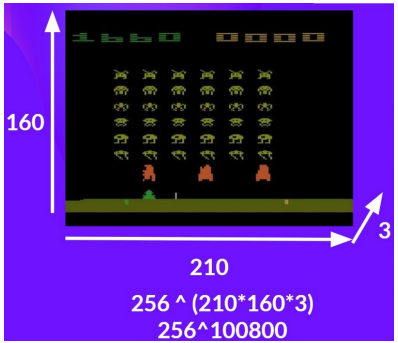
Algorithm 14: Sarsamax (Q-Learning)

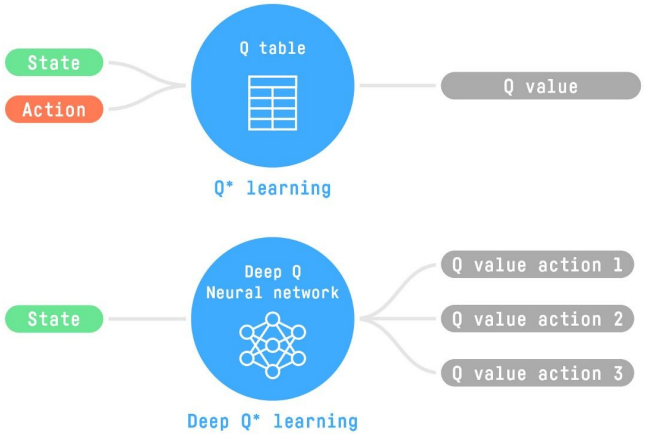
Input: policy π, positive integer *num_episodes*, small positive fraction α, GLIE $\{\epsilon_i\}$
Output: value function Q ($\approx q_\pi$ if *num_episodes* is large enough)
Initialize Q arbitrarily (e.g., $Q(s,a) = 0$ for all $s \in \mathcal{S}$ and $a \in \mathcal{A}(s)$, and $Q(\textit{terminal-state}, \cdot) = 0$)
for $i \leftarrow 1$ ***to*** *num_episodes* **do** Step 1
  $\epsilon \leftarrow \epsilon_i$
  Observe S_0
  $t \leftarrow 0$
  repeat
    Choose action A_t using policy derived from Q (e.g., ϵ-greedy) Step 2
    Take action A_t and observe R_{t+1}, S_{t+1} Step 3
    $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha(R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t))$ Step 4
    $t \leftarrow t + 1$
  until S_t *is terminal*;
end
return Q

https://projects.johnqian.com/qlearning

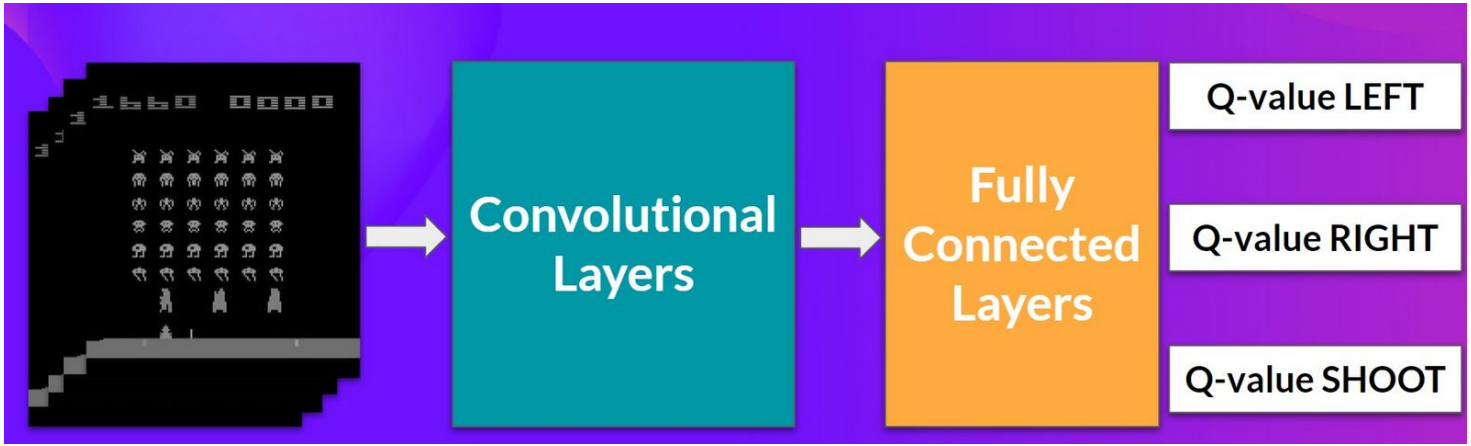
Deep RL Course (huggingface)

ГЛАВА 4 _Deep Q-learning





https://cs.stanford.edu/people/karpathy/convnetjs/demo/rldemo.html



ГЛАВА 4 _ ПР2. Принятие решений

ПР2. Принятие решений (7 баллов)

Вариант 1. Закрепление материала.

Задание 1. ИИ на основе полезности. Спроектируйте ИИ на основе полезности для некоторого NPC:
- Описание NPC, действия, функции полезности *(1 балл)*
- Есть хотя бы одно композитное действие *(1 балл)*
- Приведено несколько примеров при различный входных данных*(1 балл)*

Задание 2. Q-learning. Изучите правила и запустите моделирование на ресурсе https://www.mladdict.com/q-learning-simulator на 15-20 эпохах. Сохраните полученную матрицу. Приведите 1-2 итерации (не эпохи!) ручным счетом (как в лекции). *(2 балла)*
Обучите агента 2-3 раза с нуля на сервисе с разными настраиваемыми гипер параметрами на 10-20 эпохах. Сохраняйте результирующие матрицы. Сделайте вывод о влиянии гиперпараметров. Для каждой результирующей матрицы постройте матрицу “политик” и цепочку состояний и действий на основе этих политик от начального состояния до конечного состояния. *(2 балла)*

ГЛАВА 4 _ ПР2. Принятие решений

ПР2. Принятие решений (7 баллов)

Вариант 2. Для тру прогеров.

Опция 1. ИИ на основе полезности. Спроектируйте ИИ на основе полезности для некоторого NPC и реализуйте в Unreal Engine 4. Продемонстрируйте работоспособность разработанного ИИ *(7 баллов)*.

Опция 2. Q-learning. Реализация Q-learning на Python и применение к двум окружениям. Описание задания и шаблон для решения: https://huggingface.co/learn/deep-rl-course/unit2/hands-on *(7 баллов)*

Спасибо
за внимание!

ITMO more than a UNIVERSITY

tatyana.atyapsheva@mail.ru
abrosimov.kirill.1999@mail.ru